

Números de punto flotante, redondeo y error relativo

1. Forma de un número de punto flotante

Consideremos números de punto flotante de la forma

$$x = \pm(1 + f)2^n,$$

donde $n \in \mathbb{Z}$ es el exponente y

$$f = \sum_{i=1}^d b_i 2^{-i}, \quad b_i \in \{0, 1\}.$$

El entero d representa la precisión binaria.

Podemos reescribir f como

$$f = 2^{-d} \sum_{i=1}^d b_i 2^{d-i} = 2^{-d} z,$$

donde

$$z = \sum_{i=1}^d b_i 2^{d-i}.$$

El número z es simplemente el entero cuya representación binaria está dada por los bits

$$b_1 b_2 \cdots b_d.$$

Por tanto,

$$z \in \{0, 1, \dots, 2^d - 1\}.$$

El valor mínimo $z = 0$ se obtiene cuando todos los bits son cero, mientras que el máximo

$$z = 2^d - 1$$

se obtiene cuando todos los bits son uno:

$$2^{d-1} + 2^{d-2} + \cdots + 2 + 1 = 2^d - 1.$$

2. ¿Por qué los flotantes están en $[2^n, 2^{n+1})$?

Como

$$f = 2^{-d}z, \quad z \in \{0, 1, \dots, 2^d - 1\},$$

tenemos

$$0 \leq f \leq 1 - 2^{-d} < 1.$$

Por consiguiente,

$$1 \leq 1 + f < 2.$$

Multiplicando por 2^n ,

$$2^n \leq (1 + f)2^n < 2^{n+1}.$$

Así, para un exponente fijo n , los números de punto flotante positivos se encuentran en

$$\boxed{[2^n, 2^{n+1})}.$$

El extremo izquierdo está incluido porque $f = 0$ es posible:

$$(1 + 0)2^n = 2^n.$$

En cambio, 2^{n+1} no se obtiene con el exponente n , pues para ello necesitaríamos $f = 1$, valor que no está permitido. Sin embargo,

$$2^{n+1} = (1 + 0)2^{n+1},$$

por lo que sí aparece como el primer flotante del intervalo siguiente.

3. Separación entre flotantes consecutivos

Los flotantes correspondientes a dos valores consecutivos z y $z + 1$ son

$$x_z = \left(1 + \frac{z}{2^d}\right) 2^n$$

y

$$x_{z+1} = \left(1 + \frac{z+1}{2^d}\right) 2^n.$$

Su separación es

$$\begin{aligned} x_{z+1} - x_z &= \left(\frac{z+1}{2^d} - \frac{z}{2^d}\right) 2^n \\ &= \frac{1}{2^d} 2^n \\ &= 2^{n-d}. \end{aligned}$$

Por tanto, dentro del intervalo

$$[2^n, 2^{n+1}),$$

la distancia entre flotantes consecutivos es constante e igual a

$$\boxed{2^{n-d}}.$$

Si definimos

$$\epsilon_{\text{mach}} = 2^{-d},$$

entonces esta separación puede escribirse como

$$\boxed{2^n \epsilon_{\text{mach}}}.$$

4. La función de redondeo

Sea

$$\text{fl}(x)$$

el número de punto flotante más cercano al número real x .

Si dos flotantes consecutivos están separados una distancia

$$2^{n-d},$$

el peor caso para el redondeo ocurre cuando x se encuentra exactamente a la mitad entre ellos.

Por tanto,

$$|\text{fl}(x) - x| \leq \frac{1}{2} 2^{n-d}.$$

Es decir,

$$\boxed{|\text{fl}(x) - x| \leq 2^{n-d-1}}.$$

Esta cantidad es una cota para el *error absoluto de redondeo*.

5. Error relativo

Supongamos ahora que

$$x \in [2^n, 2^{n+1}).$$

Entonces

$$|x| \geq 2^n.$$

Como

$$|\text{fl}(x) - x| \leq 2^{n-d-1},$$

se tiene

$$\frac{|\text{fl}(x) - x|}{|x|} \leq \frac{2^{n-d-1}}{2^n}.$$

Simplificando,

$$\frac{2^{n-d-1}}{2^n} = 2^{-d-1}.$$

Como

$$\epsilon_{\text{mach}} = 2^{-d},$$

obtenemos

$$\boxed{\frac{|\text{fl}(x) - x|}{|x|} \leq \frac{1}{2} \epsilon_{\text{mach}}}.$$

Esta es una cota para el *error relativo de redondeo*.

6. Interpretación

El error absoluto depende del tamaño de x . En efecto,

$$|\text{fl}(x) - x| \leq 2^{n-d-1},$$

y esta cantidad aumenta cuando aumenta n .

Sin embargo, el error relativo satisface

$$\frac{|\text{fl}(x) - x|}{|x|} \leq \frac{1}{2} \epsilon_{\text{mach}},$$

y esta cota ya no depende de n .

Por ello, los números de punto flotante no mantienen una precisión absoluta uniforme en toda la recta real. Lo que mantienen, aproximadamente, es una precisión relativa uniforme.

En otras palabras, conforme crece el tamaño de los números, también aumenta la separación entre flotantes, pero lo hace en la misma proporción que el tamaño de los propios números.

Esta es la razón por la cual la aritmética de punto flotante conserva aproximadamente el mismo número de cifras significativas.

7. Ejemplo con $d = 3$

Si $d = 3$, entonces

$$\epsilon_{\text{mach}} = 2^{-3} = \frac{1}{8}.$$

En el intervalo

$$[2^n, 2^{n+1}),$$

la separación entre flotantes es

$$2^{n-3}.$$

Por ejemplo, si $n = 0$, los flotantes son

$$1, \quad 1 + \frac{1}{8}, \quad 1 + \frac{2}{8}, \quad \dots, \quad 1 + \frac{7}{8}.$$

La separación es

$$\frac{1}{8},$$

y el error absoluto máximo al redondear al flotante más cercano es

$$\frac{1}{16}.$$

El error relativo queda acotado por

$$\frac{1}{2}\epsilon_{\text{mach}} = \frac{1}{16}.$$

Idea central

La cadena de razonamiento puede resumirse así:

$$\text{separación} = 2^{n-d}$$

$$\text{error absoluto máximo} = \frac{1}{2} 2^{n-d} = 2^{n-d-1}$$

y finalmente

$$\text{error relativo máximo} \leq \frac{1}{2} \epsilon_{\text{mach}}.$$